

Trabajo Final – Modelos de Lenguaje

Decidimos construir un asistente conversacional especializado en la Ley de Urgente Consideración (LUC) de Uruguay. La idea era desarrollar una herramienta capaz de responder preguntas legales usando únicamente el contenido de dicha ley, sin inventar información ni apoyarse en conocimiento externo.

Esta ley abarca una amplia gama de temas, incluyendo seguridad pública, educación, economía y salud, y fue presentada como una herramienta para implementar rápidamente las políticas del nuevo gobierno.

La LUC se aprobó usando un mecanismo que obliga al Parlamento a tratarla en un plazo corto. Si no lo hace, se aprueba automáticamente. Ese formato generó muchas discusiones. El gobierno defendía la ley como clave para avanzar rápido con sus reformas, pero otros sectores cuestionaban tanto el contenido como la forma acelerada en que se trató. La discusión fue tan grande que en 2022 hubo un referéndum para intentar derogar parte de la ley, aunque finalmente la mayoría decidió mantenerla.

Es por esto que creímos útil la creación de un chatbot especializado en dicha ley.

Toda la normativa está disponible en IMPO: <https://www.impo.com.uy/bases/leyes/19889-2020>

Preprocesamiento y parseo

Trabajamos con el texto completo de la Ley de Urgente Consideración en formato PDF, y utilizamos la librería pdfminer.six para extraer todo el contenido de forma automatizada. Una vez obtenido el texto, lo limpiamos eliminando saltos de línea y espacios duplicados para dejarlo lo más prolijo posible.

En cuanto al parseo, tomamos la decisión de dividir el texto en chunks usando como delimitador cada artículo. En lugar de cortar por bloques de texto fijos o simplemente por longitud, elegimos usar la estructura natural de la ley, que son los artículos. Esto nos permitió generar chunks que tuvieran sentido por sí mismos y que fueran más útiles al momento de recuperar información relevante.

Modelo

Probamos varios modelos antes de definirnos por uno. Si bien al principio exploramos opciones como Phi-2 o TinyLLaMA por su liviandad, no logramos buenos resultados: generaban respuestas muy vagas o directamente no respondían con base en el contexto. También llegamos a correr LLaMA 3 de 8B, pero era demasiado pesado para nuestro entorno local y demoraba mucho.

Finalmente nos decidimos por LLaMA 3.2–1B porque fue el que mejor balanceó rendimiento y tiempos de respuesta. No fue una elección planificada de entrada, sino más bien el resultado de probar distintas alternativas y quedarnos con la que funcionó mejor en la práctica.

Ejecutamos el modelo usando la librería Transformers de Hugging Face, cargándolo directamente desde su repositorio oficial.

Embeddings

Para los embeddings usamos el modelo intfloat/e5-base, que ya habíamos visto funcionar en el curso para este tipo de tareas. Este modelo requiere agregar el prefijo “passage:” a cada chunk y “query:” a cada pregunta, cosa que respetamos en el pipeline.

En cuanto al indexado, usamos FAISS como índice vectorial porque también lo habíamos trabajado en el curso. Se apeló a utilizar soluciones ya validadas en el curso para un caso de uso muy similar al nuestro.

RAG

El sistema RAG quedó armado en dos etapas: primero, cuando llega una pregunta, se convierte en embedding y se buscan los k chunks más parecidos en el índice. Después, esos chunks se combinan con la pregunta y se le pasan al modelo generativo para construir la respuesta.

Prompting

A lo largo del desarrollo se exploraron distintos estilos de prompting, variando tono o restricciones. Si bien no se utilizó una técnica, se optó por un enfoque práctico: se probaron varios prompts hasta encontrar aquel que generara respuestas coherentes, sin alucinar y con mayor ajuste al contexto legal (LUC).

El prompt final le pide al modelo actuar como un abogado especializado en la LUC, basarse únicamente en fragmentos del RAG, evitar inventar o formular nuevas preguntas y retornar una frase estándar si no encuentra contexto.

Frontend



Asistente Legal LUC

Consultá artículos de la Ley de Urgente Consideración (LUC) de Uruguay. Escribí una pregunta y el sistema legal responderá en base a la ley.

¿Cuál es tu consulta legal?

¿Que dice la Ley sobre el chorizo artesanal?

Consultar

✓ Respuesta encontrada:

El artículo 366 de la Ley de Urgente Consideración (LUC) de Uruguay establece que las carnicerías de corte en todo el territorio nacional pueden elaborar productos embutidos con carne fresca (chorizo carnicero artesanal). Encomiéndase al Poder Ejecutivo, en un plazo de noventa días a partir de la promulgación de la presente ley, con asesoramiento previo del Instituto Nacional de Carnes, la redacción o modificación del protocolo técnico a seguir por dicho Instituto en su carácter de órgano con competencia atribuida en materia de habilitación e inspección de locales de carnicerías que elaboran los productos indicados en la presente disposición. Queda prohibida su venta al por mayor, distribución y su exportación.

Fragmento de la ley: Artículo 367. (Autorización a las carnicerías de corte).- Sustitúyese el artículo 2º de la Ley Nº 19.782, de 23 de agosto de 2019, por el siguiente: "ARTÍCULO 2º.- Autorízase a las carnicerías de corte en todo el territorio nacional la elaboración de productos embutidos con carne fresca (chorizo carnicero artesanal). Encomiéndase al Poder Ejecutivo, en un plazo de noventa días a partir de la promulgación de la presente ley, con asesoramiento previo del Instituto Nacional de Carnes, la redacción o modificación del protocolo técnico a seguir por dicho Instituto en su carácter de órgano con competencia atribuida en materia de habilitación e inspección de locales de carnicerías que elaboran los productos indicados en la presente disposición. Queda prohibida su venta al por mayor, distribución y su exportación".

Asistente Legal LUC

Consultá artículos de la Ley de Urgente Consideración (LUC) de Uruguay. Escribí una pregunta y el sistema legal responderá en base a la ley.

📄 ¿Cuál es tu consulta legal?

¿Que dice la Ley sobre las armas de fuego?

Consultar

✅ Respuesta encontrada:

El uso de armas de fuego es una medida extrema. No deberán emplearse las mismas excepto cuando una persona ofrezca resistencia al accionar policial con arma propia o impropia con capacidad letal o de apariencia letal, o ponga en peligro la integridad física o la vida del personal policial actuante o de terceros, y no se la pueda reducir o detener utilizando medios no letales. A los efectos de esta norma, se entiende por empleo de las armas de fuego la acción de efectuar disparos. Queda excluido de este concepto el mero hecho de esgrimir el arma en el ámbito operativo.

Fragmento de la ley: Artículo 48. (Procedimiento policial).- Sustitúyese el artículo 22 de la Ley N° 18.315, de 5 de julio de 2008 (Ley de Procedimiento Policial), por el siguiente: "ARTÍCULO 22. (Límites para el empleo de las armas de fuego).- En el marco establecido por el artículo 20 de la presente ley, el uso de armas de fuego es una medida extrema. No deberán emplearse las mismas excepto cuando una persona ofrezca resistencia al accionar policial con arma propia o impropia con capacidad letal o de apariencia letal, o ponga en peligro la integridad física o la vida del personal policial actuante o de terceros, y no se la pueda reducir o detener utilizando medios no letales. A los efectos de esta norma, se entiende por empleo de las armas de fuego la acción de efectuar disparos. Queda excluido de este concepto el mero hecho de esgrimir el arma en el ámbito operativo". - 33 -

Backend

El backend fue construido con FastAPI. Cuando llega una pregunta, lo primero que hace es convertirla en un embedding con el modelo e5-base. Ese embedding se compara contra todos los chunks de la ley que habíamos indexado previamente usando FAISS. Se seleccionan los más parecidos (según el valor k), y esos fragmentos se combinan con la pregunta en un prompt. Ese prompt se pasa al modelo generativo LLaMA 3.2, que genera la respuesta final. Todo ese proceso ocurre en una única función que conecta los embeddings, la búsqueda en FAISS y la generación del texto, arrojando una respuesta.

Conclusiones

Uno de los aprendizajes más valiosos fue descubrir y aplicar Docker. No lo habíamos usado antes y nos sorprendió lo simple que fue implementarlo. Con muy poco código logramos encapsular toda la aplicación y dejarla lista para ejecutar en cualquier máquina, sin tener que instalar nada más.

Nos pareció una solución ideal para compartir este tipo de proyectos, sobre todo si se apunta a usuarios con un perfil técnico más básico.

También aprendimos mucho sobre cómo estructurar los datos. Al principio usamos chunks de tamaño fijo, pero eso nos generaba problemas porque muchas veces cortaban artículos por la mitad o dejaban fuera información clave. Pasar a un esquema de chunks variables delimitados por artículo mejoró muchísimo la calidad del contexto que se recuperaba.

En cuanto a los modelos, hubo varios que probamos y que terminaron siendo poco prácticos. Algunos eran demasiado pesados para correrlos en local, como LLaMA 3.2–8B, y otros directamente no generaban respuestas útiles. Después de bastante prueba y error, encontramos un equilibrio con el modelo LLaMA 3.2–1B, que funcionó bien y fue razonable en tiempo de respuesta.

Sabemos que hay muchas cosas que se pueden seguir afinando. El prompt lo armamos de manera práctica, sin demasiada teoría detrás, y también podríamos haber probado más valores de k o explorar modelos más especializados en lenguaje jurídico.